

Continual Learning for Network Intrusion Detection Systems

PROGETTO CYBERSECURITY

Prof. Michele Colajanni
Dott.sa Isabella Marasco

Candidati
Stefano Casini, Luigi Lauriola, Francesco Rondini

Indice

- Introduzione
- Concetti Chiave
- Implementazione
- Risultati
- Analisi Criticità & Conclusione



Introduzione

Introduzione

- Complessità delle minacce informatiche aumenta in maniera esponenziale
- **IDS** (Intrusion Detection System) basati sull'AI sono fondamentali per la difesa delle reti, capaci di individuare comportamenti anomali
- *Limite*: le minacce informatiche si evolvono e cambiano nel tempo, rendendo difficile mantenere un'efficacia costante

Introduzione - Limiti degli IDS Statici

- Ciclo di vita IDS si basa su una fase di addestramento **offline**
- Paradigma "statico" è **inadeguato** di fronte alla velocità con cui emergono nuove tipologie di attacco e all'evoluzione della rete
- *Soluzione*: riaddestrare periodicamente il modello da zero
 - *Approccio costoso dal punto di vista funzionale*
 - *Tempi di inattività elevati*
 - *Problemi di Scalabilità e di Privacy*

Introduzione - Catastrophic Forgetting

- Aggiornare il modello esistente solo con i nuovi dati disponibili (fine-tuning)
- *Criticità: Catastrophic Forgetting*
 - "Dimentica" improvvisamente gli attacchi passati
- **Continual Learning** nasce proprio per risolvere questo conflitto

Introduzione - Obiettivo del Lavoro

- Superare i limiti degli IDS statici attraverso l'adozione del **Continual Learning**
- IDS capace di apprendere continuamente dai flussi di dati in arrivo senza compromettere quelle pregresse

ICaRL

DER


MER

- Analisi: architettura sperimentale basata su Avalanche
- Ottimizzazione automatica degli iperparametri: *Optuna*



Concetti Chiave

Network Intrusion Detection System (NIDS)



NIDS – Signature Based

- Firma
- Database di firme note
- Algoritmi di pattern Matching



NIDS – Signature Based

Vantaggi:

- Elevata precisione
- Elevata efficienza

Svantaggi:

- Non sono in grado di rilevare attacchi Zero Day
- Efficacia sensibile ad alcune tecniche di evasione (offuscamento o polimorfismo)
- Aggiornamento e mantenimento database firme oneroso

NIDS – Anomaly Based



- Modello comportamentale (baseline) del traffico legittimo
- 2 Fasi distinte:
 - Training
 - Detection
- Soglia di tolleranza

NIDS – Anomaly Based

Vantaggi:

- Capacità di rilevare attacchi Zero Day
- Capacità di rilevare attacchi mai osservati in precedenza

Svantaggi:

- Generazione di falsi positivi
- Staticità dei modelli di Machine Learning
 - Concept Drift
 - Re-Training

Continual Learning

- Adattamento continuo
 - Data stream dinamici
 - Concept drift & Zero-Day
- Efficienza
 - Nessun retraining completo
 - Risparmio computazionale



Limiti del Continual Learning

Catastrophic
Forgetting

Stabilità e plasticità

Class Incremental Learning

- Apprendimento sequenziale
 - Nuove classi di attacco arrivano nel tempo
- Inferenza Task-Agnostic
 - Nessun Task-ID durante il test

Strategie Replay based

Obiettivo: Approssimare e recuperare la distribuzione dei dati passati per riproporla durante l'addestramento sui nuovi task





Implementazione

Preprocessing - Descrizione dei Dataset

1. CICIDS2017

- simula un comportamento di rete realistico
- traffico legittimo e tipologie di attacco più comuni
- flussi di rete generati da protocolli ampiamente utilizzati e protocolli di posta elettronica

2. UNSW-NB15

- combina attività normali e attacchi moderni
- include nuove famiglie di attacchi
- complesso dal punto di vista statistico

Preprocessing - Pipeline

1. Pulizia dei Dati (Data Cleaning)

- gestione dei valori infiniti: *inf* e *-inf* convertiti in *NaN*
- rimozione dei valori mancanti

2. Encoding delle Etichette (Label Encoding)

- classi degli attacchi e traffico legittimo trasformati in numeri
- coerenza tra training, validazione e test

3. Feature Engineering e Normalizzazione

- creazione di feature derivate (rapporti tra pacchetti/trasformazioni logaritmiche)
- normalizzazione delle feature numeriche: *Min-Max scaling*


Preprocessing - Data Stream

La strategia di suddivisione dei task varia in base allo scenario operativo testato

- **Scenario Fixed**
 - classi del dataset divise equamente in gruppi di dimensione fissa definita da un parametro 'k' (es. 1+1+1...)
- **Scenario Incremental**
 - suddivisione in macro-esperienze di dimensione variabile (es. 2+3+...classi), costringendo il modello ad adattarsi a carichi di lavoro sempre più eterogenei
- **Scenario Half**
 - suddivisione delle classi in 2 macro-esperienze di dimensione fissa

Architettura Modello

- Multi-Layer Perceptron
 - 4 Hidden Layer Fully Connected
 - Struttura ad imbuto
- Blocchi modello
 - Feature Extractor
 - Linear Classifier



Architettura Modello – Scelte implementative

- Layer Normalization
- Leaky ReLU
- Dropout Dinamico



Framework di Continual Learning: Avalanche

Principi fondamentali:

- Completezza e coerenza
- Facilità d'uso
- Riproducibilità
- Modularità
- Efficienza



Avalanche: Moduli

- Benchmarks
 - Creazione e gestione dei data stream
- Training
 - Implementazione delle strategie e loop di addestramento
- Evaluation
 - Calcolo delle metriche in tempo reale

Strategie implementate

ICaRL

DER

MER

ICaRL (Incremental classifier and representation learning)

Nearest mean of
exemplars


Herding

Loss function

ICaRL – Nearest mean of exemplars


- Estrazione
- Calcolo prototipi
- Decisione

$$y^* = \operatorname{argmin}_y || \varphi(x) - \mu_y ||$$




ICaRL – Herding

- Selezione basata sulla media (Mean-of-Features)
- Memoria a dimensione fissa



ICaRL – Loss function

- Classification Loss
 - Scopo: Imparare a riconoscere le nuove classi correnti
 - Metodo: Binary Cross-Entropy sui dati attuali
- Distillation Loss
 - Scopo: Prevenire il Catastrophic Forgetting
 - Metodo: Costringe la rete ad imitare gli output del modello precedente (Teacher-Student)



DER (Dark Experience Replay)

- Strategia più avanzata rispetto al Replay Classico
- Dark Knowledge
 - Mantenere meglio il comportamento appreso in precedenza
 - Ridurre il rischio di dimenticare ciò che ha appreso in passato




DER – Reservoir Sampling e Logits

- La gestione della memoria è progettata per catturare anche la certezza e le relazioni tra le classi
- Il buffer di memoria è strutturato per ospitare triple (x, y, z)
 - dato in input
 - etichetta
 - vettore dei logits
- Politica di aggiornamento: approccio di *Reservoir Sampling*
 - medesima probabilità per ogni campione di essere presente nella memoria


DER – Optimization & Consistency

- Combinazione di esempi correnti e di esempi recuperati dalla memoria (*Replay*)
- Funzione di perdita totale $L = L_{ce} + L_{mse}$
 - Classification Loss (L_{ce}): serve a far imparare al modello i nuovi dati
 - Consistency Loss (L_{mse}): preserva la Dark Knowledge acquisita nei task precedenti
- Bilanciamento tramite l'iper-parametro α



DER – Optimization & Consistency

- DER salva le predizioni del modello nel momento in cui era "esperto" di quel task
 - + stabile
 - + affidabile
 - riduce il *Catastrophing Forgetting*



MER (Meta-Experience Replay)

Integrazione Meta-Learning
su Experience Replay

Processo aggiornamento dei
pesi ottimizzato


MER – Gestione della Memoria

- Selezione Casuale Stratificata
 - Reservoir Sampling
- Rappresentatività Temporale
 - Distribuzione dei campioni uniforme nel tempo




MER – Strategia di Aggiornamento

- Gradient Alignment:
 - Meta-Learning Objective
 - Vincolo di Allineamento
 - Direzione coerente ai gradienti passati



MER – Processo di Addestramento

- Interference-Transfer Trade-Off
 - Inner Loop (Look-Ahead)
 - Meta-Update (Reptile-Like)



Ottimizzazione degli Iperparametri



- Memory buffer
- Learning Rate
- Architettura dei 4 layer

Optuna Framework


- Pipeline Automatica
- Approccio eager (define by run)
- Set di parametri identificato matematicamente
- Meccanismi di Pruning
 - Median Pruner
 - Hyperband Pruner



OPTUNA

Optuna – Architettura

- Study
- Trial
- Objective Function



Orchestrazione degli Esperimenti




Tipo Metodo	Tipologia		
	Fixed	Incremental	Half
 ICaRL			
 MER			
 DER			

- Matrice di Esperimenti:
 - Strategie Disponibili (ICaRL, DER, MER)
 - Scenari ($1+1+...$, $2+3+...$, $5+5+...$)
- Isolamento degli studi
- Automazione






Risultati




Scenario Fixed su Dataset UNSW-NB15






Scenario Fixed su Dataset CICIDS2017






Scenario Incremental su Dataset UNSW-NB15






Scenario Incremental su Dataset CICIDS2017



Scenario Half su Dataset UNSW-NB15



Scenario Half su Dataset CICIDS2017





Analisi Criticità & Conclusione

Limitazioni e criticità nel modello

Risorse

→ Risorse computazionali elevate




Privacy

→ Replay buffer = rischio leakage

Conclusioni

- Obiettivo principale: il CL può rendere un IDS più adattivo?
- Tecniche di replay e Regularizzazione sono fondamentali per mantenere prestazioni stabili nel tempo



The image features a dark blue background with abstract teal geometric lines in the corners. In the top-left corner, several parallel lines form a corner shape. In the bottom-left corner, there are more parallel lines, some horizontal and some angled. In the bottom-right corner, three parallel lines extend diagonally upwards towards the center.

Grazie per l'attenzione